

理论控也能看懂的线代笔记 Ver 1.2

因果交流电灯

$\because \therefore \sim \otimes$



前言

本笔记修改了大部分科大教材以及课程的讲解顺序，并且引入了很多作者自己关于线性代数的不同视角。这本笔记目前绝对不适合作为一本复习笔记使用，可能也不适合作为一本学习笔记使用，因为它并没有简洁明了的公式罗列以及对于考点和知识点的分析。整篇笔记中充斥着大量对解题没有实际帮助的文字叙述，并且没有任何详细的推导过程。我想这本笔记适合给那些在课堂以及作业中学习了线性代数相关知识点，但是却希望**探索其背后的数学图像以及深层含义的同学**。这篇笔记的上半部分侧重于导出看待矩阵的四种视角，下半部分则讲述常规的应用。关于线性代数中的大部分定理以及某些公式的数学意义，我都给出了一个我认为比较能够令人满意的解释。

本笔记开始编写于 2025 年线代期末考试前后，但由于完成度问题未公开。一年之后，我将其加以修缮，补完了关于秩和奇异值分解的章节，这本笔记也终于成为了一本完整的笔记。不过作为物院的学生，我之后也一定會在某些地方专门补充上线性代数在物理中的运用，且强调其重要性。笔记的标题

理论控也能看懂的线代笔记 和理论物理并没有什么关系，只是单纯的在玩一部作品中的梗。

这篇笔记是我大一时所写，未经精心修缮，也充斥着大量我的个人风格，请大家正确地看待这本笔记的价值和学术水平，不要因为它看上去有着一定的完成度，就认为你应该使用它。若您对整篇笔记有什么意见或建议，可以联系 2263467979 (QQ)。后续可能的更新会放在我的个人网站

<https://sulcop5.github.io/> 上。

上半部分

上半部分, 侧重四种视角的导出以及其概念阐释.
至于是哪四种视角? 请看下文.

线
代
之
理
，
尽
在
其
中
。

1 方程组

1.1 记号: 矩阵

我们可以把线性方程组 (多元一次方程组) 写成类似于一个**矩阵**的形式, 记这个矩阵为 A . 不含常数项的矩阵叫做**系数矩阵**, 含常数项的矩阵叫做**增广矩阵**. 注意到, 这里的未知数有且仅有三个 (x, y, z) , 我们把这个三元组叫做向量, 记作 $\boldsymbol{x}$. 同样, 我们把三个常数 (b_1, b_2, b_3) 记作 $\boldsymbol{b}$. 由此, 我们可以把这样一个方程组简记作 $A\boldsymbol{x} = \boldsymbol{b}$.

$$A\mathbf{x} = \mathbf{b} : \begin{cases} a_{11}x + a_{12}y + a_{13}z = b_1 \\ a_{21}x + a_{22}y + a_{23}z = b_2 \\ a_{31}x + a_{32}y + a_{33}z = b_3 \end{cases} \rightarrow \left[\begin{array}{ccc|c} a_{11} & a_{12} & a_{13} & b_1 \\ a_{21} & a_{22} & a_{23} & b_2 \\ a_{31} & a_{32} & a_{33} & b_3 \end{array} \right]$$

- **注意:** 这里引入矩阵和向量只是单纯为了使得信息表达更加紧凑, 不涉及后续的矩阵运算性质. 可以发现, 我们少写了很多个 " $x+$ ", " $y+$ ", " $=$ " 等等符号.

1.2 初等行变换

在本笔记的语系中, 三种初等行变换分别称为:

- 行交换 (swap)
- 行倍乘 (mult)
- 行倍加 (plus)

注意这好像并不是官方的称呼. 后续内容也涉及初等列变换. 但在解方程组中, 我们只关心行变换.

1.3 Gauss 消元法

Gauss 消元法用于将一个矩阵化简为行阶梯形矩阵 (REF, row echelon form) 或者简化行阶梯形矩阵 (RREF, reduced row echelon form) REF, RREF, 主元列的概念自行了解.

步骤如下:

1. 从最左侧的主元列开始, 通过 swap, 使得该列最上方的元素变成非零元素. 这个最上方的元素称为**主元**.
2. 使用 plus, 使得主元列内, 主元下面的元素全部变为零, 而主元非零.
3. 暂时忽略主元列以及主元位置所在的行, 剩下一个子矩阵. 对剩下的子矩阵重复步骤 1, 直到没有非零行需要处理.
到此为止我们已经成功将矩阵化简为 REF.
4. 要继续化简为 RREF, 只需从最**右边**的主元开始, 把每个主元上方的所有元素全部化为 0. 若主元不是 1, 利用 mult 将其化为 1.

$$\left[\begin{array}{ccc|c} a_{11} & a_{12} & a_{13} & b_1 \\ a_{21} & a_{22} & a_{23} & b_2 \\ a_{31} & a_{32} & a_{33} & b_3 \end{array} \right] \longrightarrow \left[\begin{array}{ccc|c} 1 & * & * & * \\ 0 & 1 & * & * \\ 0 & 0 & 1 & * \end{array} \right] (\text{REF}) \longrightarrow \left[\begin{array}{ccc|c} 1 & 0 & 0 & x \\ 0 & 1 & 0 & y \\ 0 & 0 & 1 & z \end{array} \right] ($$

1.4 线性方程组的解

若一个线性方程组有解, 则我们称其为相容的. 反之, 无解称为不相容.
线性方程组相容 等价于 增广矩阵的 REF / RREF 最右侧不是主元列.

其中, 主元列所对应的变量叫做基本变量, 其他变量称作自由变量.
 若线性方程组相容, 则可能存在以下两种情况:

1. 无自由变量, 有**唯一**解;
2. 有自由变量, 有无数解.

1.5 解方程组的步骤

1. 写出方程组的增广矩阵.
2. 把增广矩阵化简为 RREF. 过程中若发现不相容则可直接停止.
3. 写出 RREF 所对应的方程组.
4. 把非零方程改写为由自由变量表示的形式
 特别地, 取常数项均为 0, 此方法仍然成立. 但是为什么我要专门说解 $A\mathbf{k} = \mathbf{0}$ 的解法呢?

1.6 平凡解

易知, $A\mathbf{k} = \mathbf{0}$ 的一个解是 $\mathbf{k} = \mathbf{0}$.
 其对于所有 A 全部成立, 所以其是平凡的.
 相对的, 那些 $\mathbf{k} \neq \mathbf{0}$ 的解称为是非平凡的.

1.7 通解

不难发现:

$$\begin{cases} A\mathbf{x} = \mathbf{b} \\ A\mathbf{k} = \mathbf{0} \end{cases} \rightarrow A(\mathbf{x} + \mathbf{k}) = \mathbf{b}$$

由此我们不难得出以下结论:

若我们知道了方程 $A\mathbf{k} = \mathbf{0}$ 的所有解, 那么, 只要给出 $A\mathbf{x} = \mathbf{b}$ 的任意一个解 $\mathbf{x}_0$, 就知道了这个方程的所有解 (通解).

证明方法是相减.

1.8 唯一性定理 I

(所有名字中含有"唯一性定理"的内容均为个人添加, 不是官方命名)

故, 所谓唯一性定理指的是:

若 $A\mathbf{k} = \mathbf{0}$ 的解仅有平凡解, 那么对于所有的 $\mathbf{b}$, 要么方程组 $A\mathbf{x} = \mathbf{b}$ 无解, 要么有唯一的解.

因此下列命题互相等价:

- $A\mathbf{x} = \mathbf{b}$ 要么无解, 要么仅有**唯一**解.
- $A\mathbf{k} = \mathbf{0}$ 仅有**唯一**解, 即平凡解.
- 方程组无自由变量.
- 方程组的主元列数等于变量个数 (列数).

2 向量组

本笔记中的"向量", 大部分情况下只有以下两类:

- 有限维实向量, 对应的数乘为实数数乘;
- 有限维复向量, 对应的数乘为复数数乘.

与线性空间区分, 下用 $\mathcal{V}$ (`\mathcal{V}`) 而不是 V 来表示向量组.

2.1 向量和向量组

数域上 n 个有次序的数组成的数组 (有序组) 可以称为一个**向量**. 这些数被称为分量, 数的个数被称为向量的维数.

若干个相同维度的向量可以构成**向量组**. 于是, 矩阵的各行和各列也能看作向量组.

2.2 线性组合

V 中的 n 个向量 $v_1, v_2 \dots v_n$ 的**线性组合**是形如

$$a_1 v_1 + a_2 v_2 \dots a_n v_n$$

的向量, 其中 $a_1, a_2 \dots a_n \in F$. 在本笔记中, 将这些数称为**权**.

事实上, 我们会发现:

在上一节中提到的 $A\mathbf{k} = \mathbf{0}$ 的解, 其实就是某些特定解的线性组合. 因为, 它们总是能写成类似 $x_{r_1} v_{r_1} + x_{r_2} v_{r_2} \dots x_{r_n} v_{r_n}$ 的形式. 其中, $x_{r_1} \dots x_{r_n}$ 是方程组的自由变量.


2.3 张成

V 中的向量组 $v_1, v_2 \dots v_n$ 的所有线性组合构成的集合成为向量组的**张成空间**, 记作:

$$\text{Span}(v_1, v_2 \dots v_n)$$

这里的 Span 就是**张成**.

我们可以直观的做如下理解: 首先固定一个向量 v_1 , 使其滑动, 得出一条直线. 这个滑动的过程实际就是向量前的"权"取遍 R 的过程. 然后拿出向量 v_2 , 将刚才所得的一条直线在 v_2 的方向上滑动, 由此将直线扩充至一个平面 (当然此操作需要 $v_2 \notin \text{Span}(v_1)$, 否则将会导致仍然得到一条直线). 循环往复, 我们可以得到一个三维空间, 一个四维空间...



如果这个新的向量处在原本的张成空间之内会怎么样呢? 想象平面直角坐标系沿着一三象限的对角线方向滑动, 平面仍然是平面, 没有任何变化. 这种情

况下, 操作不会产生新的维度, 原来的空间只是在自己的地盘内滑动罢了. 因此我们要求 $v_i \notin \text{Span}(v_1, v_2 \dots v_{i-1})$.

2.4 线性无关

线性无关是向量组中**极其重要**的概念.

2.4.1 线性无关的定义

若对于 $\mathcal{V}$ 中的向量组 $v_1, v_2 \dots v_n$, 如果使得

$$a_1 v_1 + a_2 v_2 \dots + a_n v_n = 0$$

成立的 $a_1, a_2 \dots a_n$ 的**唯一**选取方式是全部取为 0, 那么称该向量组**线性无关**.

2.4.2 唯一性定理 II

若取:

$$\begin{aligned} \boldsymbol{x} &= (a_1, a_2 \dots, a_n) \\ A &= [v_1, v_2 \dots, v_n] \end{aligned}$$

我们对比方程 $A\boldsymbol{x} = \mathbf{0}$ 以及上面的公式

$$a_1 v_1 + a_2 v_2 \dots + a_n v_n = 0$$

会发现这两种表述其实是等价的. 则线性无关的定义变成:

方程组 $A\boldsymbol{x} = \mathbf{0}$ 仅有平凡解.

也就是说, 线性无关和唯一性定理 I 的表述实际上相同.

2.4.3 线性相关

若向量组不线性无关, 则称其**线性相关**.

可知, 线性相关组增加别的向量, 必定仍然线性相关.

2.4.4 线性相关引理

对于 $\mathcal{V}$ 中的向量组 $v_1, v_2 \dots v_n$, 若其线性相关, 必定存在 $k \in \{1, 2 \dots m\}$ 使得:

$$v_k = \text{Span}(v_1, v_2 \dots, v_{k-1})$$

进而得出, 移除上述过程中的 v_k , 剩下的向量组的张成空间保持不变.

进而得出, 在保持向量组的张成空间不变的情况下, 我们可以不断地进行移除向量的操作, 直到剩下的向量组线性无关.

这引出了接下来的定义:

2.5 极大无关组

2.5.1 极大无关组的定义

极大无关组指的是从向量组 $\mathcal{V}$ 中选取的一个子集:

$$\{v_{i_1}, v_{i_2}, \dots, v_{i_r}\} \subseteq \mathcal{V}$$

且:

- 向量组线性无关
- 若再加入 $\mathcal{V}$ 中的其他向量, 向量组不再线性无关.

2.5.2 极大无关组的性质

- 极大无关组的元素个数唯一确定, 称为原向量组的**秩**.
秩这个概念后面才会有广泛应用, 现在可以不作过多理解.
- 一个向量组的极大无关组可能不唯一.

3 线性空间

线性空间是线性代数中极其重要的概念. 不同于 LADR 强调向量空间和线性算子, 我们在本篇笔记中暂且先不注重线性空间. 当然, 这就使得这本笔记并不能帮助我们深入线性代数的本质.

线性空间的概念及其重要, 在之后的很多学科中都有直接体现和推广. 本笔记只是受篇幅所限不展开而已.

3.1 线性空间

参考 LADR 的中的规定, 下面我们规定 V, U, W 都是线性空间.

在这本笔记中考虑的线性空间一般是 $\mathbb{R}^n$ 或 $\mathbb{C}^n$, 其对应的数域 F 分别是 $\mathbb{R}$

或 $\mathbb{C}$.

域的概念自行了解.

3.1.1 加法和数乘

一个集合 V 要称为定义在 F 上的线性空间, 我们需要先定义加法以及数乘. 下文中的符号 $\times$ 指的是直积, 所谓的"吃掉"和"吐出"代表映射.

3.1.1.1 加法

加法是一个运算, 它吃掉两个 V 中的向量, 吐出一个 V 中的向量:

$$+ : V \times V \rightarrow V, \quad (u, v) \mapsto u + v$$

并且要满足以下几条性质:

1. 加法可交换.

对于所有 $u, v \in V$, 都有 $u + v = v + u$.

2. 加法可结合.

对于所有 $u, v, w \in V$, 都有 $u + (v + w) = u + (v + w)$.

3. 存在 0_V .

存在 $0_V \in V$, 对于所有 $v \in V$, 都有 $v + 0_V = v$.

4. 存在加法逆元.

对于所有 $v \in V$, 都存在 $w \in V$, 使得 $v + w = 0$.

3.1.1.2 数乘

数乘是一个运算, 它吃掉一个 F 中的数和一个 V 中的向量, 吐出一个 V 中的向量:

$$\cdot : F \times V \rightarrow V, \quad (a, v) \mapsto av$$

并且满足以下性质:

1. 数乘可结合.

对于所有 $a, b \in F, v \in V$, 都有 $(ab)v = a(bv)$.

2. 存在 1_F .

存在 $1_F \in F$, 对于所有 $v \in V$, 都有 $1_F v = v$.

3. 满足数乘对向量加法的分配律.

对于所有 $u, v \in V, a \in F$, 都有 $a(u + v) = au + av$.

4. 满足数乘对域内加法的分配.

对于所有 $v \in V, a, b \in F$, 都有 $(a + b)v = av + bv$.

3.1.2 线性空间的定义

给定集合 V 和域 F , 给定集合上的加法和数乘的法则, 若它们满足如下定义, 就说这个集合是一个**线性空间**:

- **加法**: 可交换, 可结合, 有零元, 有逆元.
- **数乘**: 可结合, 有单位元, 有两种分配性质

容易证明, V 和 F 分别取 $\mathbb{R}^n, R$ 以及 $\mathbb{C}^n, C$ 时, 上述性质成立. 需特别注意, 其中 0_V 的是全部分量均为 0 的向量, 而非一个 R 或 C 中的数.

3.2 基

理解这部分内容时, 可以去思考三维空间中的笛卡尔坐标系. 但, 之后我们的思维必须跳脱三维空间的局限, 而是上升到高维世界乃至一般的线性空间中.

3.2.1 基的定义

V 中线性无关且张成 V 的向量组称为 V 的一组基. 符号表达为 $\mathfrak{B}$ (`\mathfrak{B}`). 或说基具有以下性质:

- 线性无关.
- 生成律 (张成 V).

3.2.2 基的性质

基具有如下的一些性质:

- 若向量组张成一个线性空间, 则这个向量组一定能被削减为此线性空间的一组基.
只需要反复运用线性相关引理的删除步骤, 直到剩下的向量组线性无关.
- 每个线性无关组都能被扩充为该线性空间的基.
- 同一个线性空间中, 基的长度是固定的.

这个固定的长度是什么呢? 下面会阐明.

3.2.3 坐标

根据定义, 若向量组 $\mathfrak{B}$ 为一组基, 任意一个 V 中的向量 x , 都等于向量组的一个**唯一**线性组合.

这个线性组合的系数 (权), 就被称为向量 x 相对于 $\mathfrak{B}$ 的坐标向量.

参考笛卡尔坐标系和笛卡尔坐标, 其中坐标轴单位向量就是欧几里得空间 $\mathbb{R}^3$ 的一组基.

3.2.4 三种视角

由此我们可以发现, 线性方程组的解, 权与线性组合, 坐标与基, 内部有着深刻的关联. 我们令 x 是 V 中的向量, 以下三个名词实际上互相等价:

- 线性方程组的解.
- 用向量组中的各向量的线性组合表示 x 的方式.
- x 在 $\mathfrak{B}$ 下的坐标.

3.3 维数

3.3.1 定义

有限维线性空间的维数, 是这个线性空间任意一个基的长度 (向量组中向量的个数). 记作 $\dim V$.

3.3.2 性质

- 线性空间的维数大于等于子空间的维数.
- 当且仅当线性空间和子空间相等时, 他们的维数相同.
- 每个长度为 $\dim V$ 的张成组都是 V 的基.

3.4 子空间

3.4.1 子空间的定义

当线性空间的子集 U 满足以下条件时, U 是 V 的**子空间**:

1. $0_V \in U$.

2. **对加法封闭**: 对任意 $u, v \in U$, 都有 $u + v \in U$.

3. **对数乘封闭**: 对任意 $v \in U, \lambda \in F$, 都有 $\lambda v \in U$.

3.4.2 子空间的性质

由上述性质我们可以推断, 子空间仍然是一个向量空间. 子空间的交集是子空间, 但是并集不一定是子空间.

3.5 什么是映射?

在接下来的内容中, 映射这个概念将反复的出现. 我们应立足于映射的定义, 从集合的角度去理解这个概念.

设有两个集合 A 和 B , **映射**就是一种对应法则, 使得集合 A 中的每一个元素都**唯一**对应着 B 中的一个元素:

$$f: A \rightarrow B$$

重申: 在理解时, 我们可以类比高中所学的函数中的概念. 但一定要超越高中对函数的狭隘理解. 虽然我们确实不是数学系的, 但也不要只停留于高中的理解水平 (

3.6 线性映射的定义

从 V 到 W 的线性映射是满足下列性质的映射 $T: V \rightarrow W$.

- **可加性**: $T(u + v) = T(u) + T(v)$.
- **齐次性**: $T(\lambda v) = \lambda T(v)$.

记全体从 V 到 W 的线性映射集合为 $\mathcal{L}(V, W)$.

3.7 唯一性定理 III

线性映射引理讲述的是以下一个事实: 若基确定, 且基在线性映射下的像确定, 那么线性映射必然唯一确定. 为和前两章的概念相吻合, 我仍将其称为唯一性定理.

用数学语言表述如下:

$\{v_1, v_2 \dots v_n\}$ 是 V 的一组基, 如果任意给定一组向量 $\{w_1, w_2 \dots w_n\} \subseteq W$, 那么:

- **存在**线性映射 $T: V \rightarrow W$, 使得每个 $T(v_k) = w_k$.
- 这个线性映射**唯一**.

证明方法: 相减后利用线性无关的定义.

回看线性无关概念 (唯一性定理 II) 中, 用加粗字体标注的"唯一"二字. 可以说, 正是这两个字, 奠定了线性映射的基础.

3.8 线性映射的运算

3.8.1 加法

$$(S + T)v = Sv + Tv$$

3.8.2 数乘

$$S(\lambda v) = \lambda S(v)$$

3.8.3 乘法

$$(ST)v = S(Tv)$$

乘法的性质:

- 具有可结合性.
- 存在乘法单位元 I .
- 具有分配性

3.9 核与像

3.9.1 零空间

零空间 (null space), 又称为**核空间 (kernel space)** 的定义如下:

$$\text{Nul } T = \{v \in V | Tv = 0\}$$

可以记作 $\text{null } T$ 或 $\text{Nul } T$ 或 $\text{Ker } T$.

可以类比函数的"零点". 只不过这里的零点可以是一个高维子空间.

3.9.2 像空间

像空间 (image space), 又称为**值域 (range)** 的定义如下 (其中 $v \in V$):

$$\text{Img } T = \{w \in W | Tv = w\}$$

可以记作 $\text{range } T$ 或 $R(T)$. 上述定义不一定严谨, 写成这种形式是为了类比零空间.

可以类比函数的值域.

3.9.3 一个数学图像

我们知道, 线性映射是从 V 到 W 的一个映射. 比如, 其可以分别为 $\mathbb{R}^n$ 和 $\mathbb{R}^m$ 的子空间.

$$\mathbb{R}^n \supset V = \left\{ \begin{array}{ll} \text{Nul } T & \xrightarrow{T} 0 \\ \text{others} & \xrightarrow{T} \text{Img } V - 0 \end{array} \right\} \text{Img } V \subset W \subset \mathbb{R}^n$$

此图对应着两个关系 (下面的斜体字体是经典类比):

- 线性映射把 V 投射到 $\text{Img } V$.
函数把定义域投射到值域.
- 线性映射把 $\text{Nul } V$ 投射到 0 .
函数把零点投射到 0 .
- 定义域包含于 $\mathbb{R}^n$.
定义域属于 R .
- 值域包含于 W .

4 矩阵

常见到类似这样的术语: $m \times n$ 的矩阵. 其中:

- m 是行 (row), 如果要数第几行的话, 从左上角的元素开始, 沿竖直方向数.
- n 是列 (column, 简称 col), 如果要数第几列的话, 从左上角的元素开始, 沿水平方向数.

4.1 矩阵的多重视角

前面的叙述为这一小节铺垫, 后面的叙述展示这一小节的意义.

1. **矩阵:** 矩阵是可以进行某些运算 (如加法 数乘 乘法) 的二维数组.

2. **方程**: 矩阵代表了一组方程组.
3. **向量**: 矩阵是一组行向量或者一组列向量.
4. **几何**: 矩阵代表了一个线性映射.
线代之理, 尽在其中.

4.2 矩阵的加法和数乘


简单.

不过细心的同学们可能已经发现, 既然矩阵有定义的加法和数乘, 那么某个特定维数 (如 3×3) 矩阵的总体, 自然地就可以被视为一个线性空间. 对于学习物理的同学们而言, 这个性质将在之后的张量学习中起到极大的作用, 然而我们现在不展开讲述.

4.3 矩阵的乘法

4.3.1 乘法计算

$m \times n$ 矩阵 和 $n \times q$ 矩阵相乘得到 $m \times q$ 矩阵, 由此我们可以如下记忆:
一个矩阵中第 i 行, 第 j 列的元素, 是第一个矩阵的第 i 行和第二个矩阵的第 j 列的向量点乘. 直观上看, 就是第一个矩阵横着画荧光笔, 第二个矩阵竖着画. 这两个线束上, 对应位置的元素乘积之和, 就是矩阵的 (i, j) 号元素.



4.3.2 线性映射视角

矩阵和线性映射存在一一对应的关系.

因此矩阵乘法可以从线性映射的复合的角度考虑.

4.3.3 向量视角

可以将矩阵和向量的乘法理解为:

- Ax : 矩阵左乘列向量, 是 $m \times n$ 矩阵乘 $n \times 1$ 矩阵, 得到 $m \times 1$ 矩阵(即列向量). 即: 用 x 的元素为矩阵的列向量加权求和. 并得到一个维数相同的列向量.
- xA : 矩阵右乘列向量, 是 $n \times 1$ 矩阵乘 $m \times n$ 矩阵, 得到 $m \times 1$ 矩阵(即列向量). 即: 用 x 的元素为矩阵的列向量加权求和. 并得到一个维数相同的列向量.

那么, 矩阵和矩阵的乘法 AB 可以理解为:

- 矩阵之积的各列, 等于矩阵 A 左乘 B 的列向量们, 等于 A 的各列以 B 的对应列的元素为权作线性组合.
- 矩阵之积的各行, 等于矩阵 B 右乘 A 的行向量们, 等于 B 的各行以 A 的对应行的元素为权作线性组合.

4.3.4 "基"变换的视角

"向量视角"中有"加权求和"这样的名词. 很容易联想到, 这实际上对应了某些类型的"基变换". 不过注意, 基这个概念只有在各个列向量线性无关的情况下才会有, 而矩阵乘法是全情况通用的.

我们假定矩阵 B 的各列分别是 $\beta_1, \beta_2, \dots, \beta_n$.

一个向量 x 可以看作其本身在 I 的各列, 也即标准基 $e_1 = (1, 0, \dots, 0)$, $e_2 = (0, 1, \dots, 0), \dots, e_n = (0, 0, \dots, 1)$ 下的坐标.

同样的, Bx 在基 $\mathfrak{B}$ 下的坐标便是 x , B 在基 $\mathfrak{B}$ 的视角下就是 I .

4.4 矩阵乘法的性质

4.4.1 运算性质

1. 乘法结合律.
2. 乘法单位元.
3. 左右分配律.
4. 数乘结合律.

4.4.2 交换性

注意, 矩阵乘法一般不满足可交换性! 满足交换性的矩阵称为**可交换矩阵**.

4.5 初等变换阵

初等行变换对应着初等矩阵.

每种初等变换都唯一对应着一个矩阵. 如何判断一个矩阵的作用是什么呢?

根据下面口诀: **行左乘, 列右乘**. 确定是行变换还是列变换了之后, 假设你的操作对象是单位矩阵, 以此判断是什么操作.

1. **swap 阵**. 例如:

$$E_{\text{swap}} = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

2. **mult 阵**. 例如:

$$E_{\text{mult}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

3. **plus 阵**. 例如:

$$E_{\text{plus}} = \begin{bmatrix} 1 & 5 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

4.6 矩阵多项式

$$f(A) = c_0 I + c_1 A + \cdots + c_k A^k$$

若有多项, 在可交换前提下, 可以写出类似二项展开的式子.

下半部分

我们将从各种角度去解读上半部分中提到各种视角.

1 迹

这小节比较简单.^[1]

数学符号是: $t(A)$ 或 $\text{tr}(A)$ 或 $\text{Tr}(A)$ 或 $\text{trace}(A)$.

1.1 迹的定义

只有方阵有迹. 迹是方阵的对角线元素之和.

1.2 性质

1. $\text{tr}(A) = \text{tr}(A^T)$.
2. $\text{tr}(A) + \text{tr}(B) = \text{tr}(A + B)$.
3. $\text{tr}(AB) = \text{tr}(BA)$.
4. 一般而言 $\text{tr}(AB) \neq \text{tr}(A) \cdot \text{tr}(B)$.
5. **Frobenius 范数:**

$$\|A\|_F = \sqrt{\text{tr}(AA^H)} = \sum |a_{ij}|^2$$

其中, $A \in \mathbb{C}^{n \times n}$, H 代表共轭转置. 对于实矩阵而言, 其就是转置.

2 行列式

数学符号是: $\det A$ 或 `\vmatrix`.^[2]

2.1 行列式的定义

下述两个定义都是最基础的代数定义, 记住第一个, 了解第二个即可. 它们只是为了推出一些行列式的性质, 很少用于计算.

2.1.1 递归定义

$$\det A = \sum_{i=1}^n (-1)^{i+1} a_{i1} M_{i1} = \sum_{i=1}^n a_{i1} A_{i1}$$

其中 M_{ij} 是删除第 i 行和第 j 列所得到的方阵的行列式, 称为**余子式**.
而 $A_{i1} = (-1)^{i+1} M_{i1}$ 是**代数余子式**.

2.1.2 逆序数定义

一般用来看清行列式的代数结构. 不要用这玩意去实际算, 除非太简单.

2.2 行列式的意义

2.2.1 矩阵视角

行列式是通过余子式定义或逆序数定义所计算出的一个数值.

此条性质并没有良好的图像. 但是它给了我们计算行列式数值的严谨方法以及其递归性质.

2.2.2 向量视角

- **行列式就是体积.**

或者说, 以矩阵的列向量或行向量为各个边, 所获得的图形 (超平行多面体) 的定向体积. 特别地, 行列式为 0 的时候, 这些向量的终点和原点共一个超平面.

2.2.3 线性映射视角

- **行列式就是变换伸缩体积的能力.**

或者说, 行列式就是在矩阵所对应的线性映射下, 图形测度的伸缩因子.

实际上其含义是: 线性映射所对应的"体积伸缩"特性是可以叠加的. 这预示着后续行列式的可乘性.

2.3 行列式的性质

2.3.1 转置不变

$$\det A = \det A^T$$

2.3.2 乘积不变

$$\det(AB) = \det(A) \cdot \det(B)$$

2.3.3 初等变换

1. 交换两行, 行列式相反.
swap 初等阵的行列式为 -1.
2. 倍乘某行, 行列式变成原来的 λ 倍.
推论: $n \times n$ 方阵数乘 λ , 行列式变成原来的 λ^n 倍.
3. 倍加变换不改变行列式.

2.3.4 可拆分性

若某一行或者列能写成向量和的形式, 则行列式也等于两个对应矩阵之和.

2.4 行列式的计算

通过逆序数的定义, 可以知道, 一个很好的性质是: 三角矩阵的行列式就等于其对角线上元素的乘积. 之后的做题也会大量的运用到这些东西

2.4.1 代数余子式计算

找个好算的行列剥蒜.

2.4.2 拆行拆列法

纯粹做题技巧.

2.4.3 加边法

纯粹做题技巧.

2.4.4 Gauss 变换

通过一系列初等变换, 化简为三角, 行列式即对角元素之积. 别忘了乘上变换过程中 swap 和 mult 造成的影响.

Gauss 老祖的威力.

2.5 Cramer 法则

系数矩阵行列式非 0 时, 线性方程组有唯一解, 解的表达式如下:

$$(x_1, x_2, \dots, x_n) = \left(\frac{\Delta_1}{\Delta}, \frac{\Delta_2}{\Delta}, \dots, \frac{\Delta_n}{\Delta} \right)$$

其中, $\Delta = \det(A)$, Δ_i 是将 A 的第 i 列换成常数项后所得到的方阵的行列式, $i = 1, 2, \dots, n$.

这揭示了上文我们没有提及的视角:

线性方程组的解和行列式之间也有定量的关系.

2.6 Vandermonde 行列式

给定给定 n 个数 $x_1, x_2, \dots, x_n$, Vandermonde 行列式定义为:

$$V(x_1, x_2, \dots, x_n) = \begin{vmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{n-1} \end{vmatrix}$$

可以化简为:

$$V(x_1, x_2, \dots, x_n) = \prod_{1 \leq i < j \leq n} (x_j - x_i)$$

3 逆

3.1 逆矩阵的定义

若 $XA = AX = I_n$, 则称 A 可逆. 且称 X 为 A 的逆矩阵.

我们可以得知, 一个矩阵的逆矩阵若**存在**, 就一定是**唯一**的. 故可以用一个数学符号 A^{-1} 去表示它.

3.2 伴随矩阵

伴随矩阵 (adjugate matrix), 符号表达为 $\text{adj}(A)$ 或 A^* .

3.2.1 伴随矩阵的定义

设 A 是一个 $n \times n$ 的方阵.

- 将 A 的每个元素 a_{ij} 用其对应的代数余子式 C_{ij} 替代, 得到一个矩阵:

$$\text{Cof}(A) = \begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1n} \\ C_{21} & C_{22} & \cdots & C_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{n1} & C_{n2} & \cdots & C_{nn} \end{bmatrix}$$

- 再进行**转置**，得到的矩阵就是 $\text{adj}(A)$.

可以发现: 上三角矩阵的伴随为上三角, 下三角矩阵的伴随为下三角.

3.2.2 伴随矩阵的运算性质

1. 乘积规则:

$$(AB)^* = B^* A^*$$

2. 转置规则:

$$\text{adj}(A^T) = (\text{adj}(A))^T$$

3. 数乘规则:

$$\text{adj}(\lambda A) = \lambda^{n-1} \cdot \text{adj}(A)$$

4. $\text{adj}(I) = I$

3.2.3 伴随矩阵与逆

以下恒等式成立. 也即: 矩阵和自己的伴随矩阵可交换:

$$AA^* = A^*A = \det(A) \cdot I$$

当 A 可逆时, 其逆可以表示为:

$$A^{-1} = \frac{1}{\det(A)} \cdot A^*$$

推论:

$$\det(A^*) = \det(A)^{n-1}$$

3.2.4 伴随矩阵与秩^[3]

1. $\text{rank}(A) = n$, 则 $\text{rank}(A^*) = n$.
2. $\text{rank}(A) = n - 1$, 则 $\text{rank}(A^*) = 1$.

3. $\text{rank}(A) \leq n - 2$, 则 $\text{rank}(A^*) = 0$.

3.2.5 什么是伴随矩阵?

也许各位线性代数的初学者看到伴随矩阵往往会不知所云, 认为其没什么用. 不过实际上, 伴随矩阵所代表的是行列式之下的"面积". 我们以三维空间为例, 行列式代表的是体积缩放因子, 而伴随矩阵则分别对应三个面的面积, 它的第一行就是后两个矢量的叉乘. 同样的, n 维矩阵的伴随矩阵就代表了 $(n - 1)$ 维子空间的面积.

这也就能够理解上述伴随矩阵与秩的关系了.^[3-1] 我们仍然以三维空间为例, 当秩为 $(3 - 1)$ 也就是 2 时, 原矩阵对应一个平面, 因此只有一个平面面积非零, 秩为 1. 而当维数更少时, 所有"超平面"的"面积"全部是 0, 伴随矩阵零秩.

3.3 逆的运算性质

1. 自身的逆

$$(A^{-1})^{-1} = A$$

2. 转置的逆

$$(A^T)^{-1} = (A^{-1})^T$$

3. 数乘的逆

$$(\lambda A)^{-1} = \frac{1}{\lambda} A^{-1}, \quad \lambda \neq 0$$

4. 乘积的逆

$$(AB)^{-1} = B^{-1}A^{-1}$$

3.4 一般求逆的方法

1. 伴随矩阵求逆

见上

2. Gauss 法求逆

初等行变换将增广矩阵 $[A, I]$ 变成 $[I, A^{-1}]$.

3.5 可逆矩阵的特征

接下来这些性质,都和矩阵可逆相互等价,且都对应着上面所说的矩阵的几种视角.

矩阵视角:

1. 存在 $C \in \mathbb{R}^n$ 使得 $CA = I$.
2. 存在 $D \in \mathbb{R}^n$ 使得 $AD = I$.
3. 转置之后仍是可逆阵.

方程视角:

4. 矩阵行等价或列等价于 I_n .
(事实上上面的 C 和 D 就可以看作是这一系列初等变换阵的连乘)
5. 矩阵有 n 个主元位置.
6. 方程 $Ax = 0$ 仅有平凡解.
7. 方程 $Ax = b$ 必定有解.

向量组视角:

8. A 的各列线性无关.
9. A 的各列张成全空间.
10. A 的各行张成全空间.

几何视角:

11. A 所对应的线性映射 $\mathcal{A}$ 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 一一对应的.
12. $\mathcal{A}$ 没有压扁任何维度.
13. $\mathcal{A}$ 所对应的线性映射是可还原的.

实际上,上述几条性质就是**满秩阵**的性质.

3.6 逆与线性映射

若矩阵 A 的各列为 $\alpha_1, \alpha_2, \dots, \alpha_n$. 线性映射 $\mathcal{A}$ 将这组向量映射为 $\beta_1, \beta_2, \dots, \beta_n$. 那么:

1. 求 $\mathcal{A}$ 在基 $e_1, e_2, \dots, e_n$ 下的矩阵:

$$\begin{cases} B \xleftarrow{T_I} A \xleftarrow{A} I \\ B \xleftarrow{B} I \end{cases}$$

$$T_1 A = B \longrightarrow T_I = BA^{-1}$$

2. 求 $\mathcal{A}$ 在基 $\alpha_1, \alpha_2, \dots, \alpha_n$ 下的矩阵:

$$B = AT_A \longrightarrow T_A = A^{-1}B$$

3. 求 $\mathcal{A}$ 在基 $c_1, c_2, \dots, c_n$ 下的矩阵:

$$T_C = C^{-1}BA^{-1}C$$

特别地, 如果你的 A 是自然基构成的矩阵 I , 可以得到:

$$T_C = C^{-1}BC$$

4. 求 $\mathcal{A}$ 在基 $\beta_1, \beta_2, \dots, \beta_n$ 下的矩阵:

$$T_B = B^{-1}BA^{-1}B = A^{-1}B = T_A$$

4 矩阵分块

事实上, 前面所表述的"将矩阵看作行向量和列向量"就是一种分块的思想.

4.1 分块矩阵的运算性质

1. 两个矩阵的分块方式相同, 则可相加.
2. 两个矩阵分块的大小相匹配, 则可相乘.

4.2 特殊分块矩阵

1. 准对角矩阵:

$$\text{diag}(A_1, A_2 \dots A_n)$$

行列式为各对角块行列式之积.

其逆为:

$$\text{diag}(A_1^{-1}, A_2^{-1} \dots A_n^{-1})$$

2. 准上 / 下三角矩阵:

3. 块初等变换阵.

4.3 分块矩阵的逆

准对角矩阵的逆见上文, 下讨论准三角矩阵:

$$\begin{pmatrix} A & C \\ O & B \end{pmatrix}^{-1} = \begin{pmatrix} A^{-1} & -A^{-1}CB^{-1} \\ O & B^{-1} \end{pmatrix}$$

类似 Gauss 化简法的方法能够得出结论. 注意是左乘还是右乘.

4.4 Schur 补

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \rightarrow \begin{bmatrix} A - BD^{-1}C & B \\ O & D \end{bmatrix}$$

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \rightarrow \begin{bmatrix} A & B \\ O & D - CA^{-1}B \end{bmatrix}$$

只需要进行两次分块矩阵的"倍加变换"即可. 由于是倍加变化, 不改变行列式, 我们可以得到:

$$\det(A) \det(D - CA^{-1}B) = \det(D) \det(A - BD^{-1}C)$$

在这里体现的, 实际上是分块矩阵的降维功能.

分块矩阵还能处理很多其他问题. 若遇到维数看上去可以放进分块矩阵中的题目, 需要注意.

5 秩

5.1 秩的定义

在上述的笔记中, 我们已经引入了秩的定义. 再重温一遍.

向量组 V 的秩 r 是其最大线性无关向量的个数, 即:

$$r = \dim \text{Span}(V)$$

这是对于一个向量组而言的. 而对于矩阵而言, 我们也需要借用向量组的定义. 自然地想到, 矩阵有其行向量组和列向量组. 于是我们可以做如下规定:

- **行秩**是矩阵行向量组的秩;
- **列秩**是矩阵列向量组的秩.

那么我们是否需要专门使用不同的术语去区分这两个量呢? 从下面的定理中可知.

5.2 行秩与列秩

我们可以得到:

$$\text{行秩} = \text{列秩}$$

详细的证明从略. 但令人惊叹的是: 对于一个 $m \times n$ 的矩阵, 虽然行向量存在于 $\mathbb{R}^n$ 中, 列向量存在于 $\mathbb{R}^m$ 中, 但行向量组与列向量组的秩相同. 因此, 我们统称其为矩阵的**秩**, 记作 $\text{rank}(A)$ 或 $r(A)$.

但目前大家对于这个结果的图像仍然一无所知, 因此, 我们需要从秩的不同理解来审视这一结果.

5.3 秩的多重视角

秩, 本质上就是用来衡量矩阵**有效信息含量**或**空间维度**的指标. 我们从四种视角来审视它:

5.3.1 方程视角

$\text{rank}(A)$ 是 Gauss 消元后, REF / RREF 中**非零行的个数**, 或者是**主元的个数**. 它代表了方程组中"真正独立, 不相互矛盾且不冗余"的方程个数.

从这个角度, 我们很好理解行秩等于列秩的原因: Gauss 消元法不改变线性相关或无关的特性, 因此行秩也就是 REF 中非零行的个数, 而列秩即是 REF 中主元列的个数. 而由于非零行的个数就等于主元列的个数, 因此行秩等于列秩.

5.3.2 向量组视角

$\text{rank}(A)$ 是矩阵中**极大线性无关组**的大小. 即, 最多能挑出多少个列 (行) 向量, 使得它们谁也无法被别人表示.

5.3.3 矩阵视角

最高阶非零子式的阶数. 如果 $\text{rank}(A) = r$, 说明矩阵里至少能抠出一个 $r \times r$ 的方阵, 它的行列式不为零. 要注意的是, 这个视角虽然看上去不直观, 但却是许多线性代数证明题的关键, 大家一定要牢记.

5.3.4 几何视角

秩代表了**像空间的维数**, 即 $\text{rank}(A) = \dim(\text{Img } A)$.

几何视角是最为直观的视角. 秩就是在线性映射 $\mathcal{A}$ 的作用下, 整个定义域空间被投射过去后, 得到的新图形的维度. *例如: 一个 3D 空间被矩阵映射后, 如果变成了 2D 的平面, 那这个矩阵的秩就是 2; 如果压成了一条线, 秩就是 1; 变成了一个点, 秩就是 0. 更加有趣的是, 由于线性映射的性质, 映射之后的空间必定包含原点, 并且也是线性空间.*

5.3.5 秩的意义

我们可以把矩阵的秩想象成一种矩阵内部的信息含量. 矩阵的秩越高, 它所描绘的信息就越复杂, 矩阵之间的元素就愈发不受到约束; 矩阵的秩越低, 它所描绘的信息就越简单, 矩阵之间的元素所受的约束就越多. *举一个简单的例子: 如果一个矩阵的大小为 3×10000 , 其中第一行是一个随机的数列, 而第二行是第一行的 2 倍, 第三行是第一行的 3 倍. 那么我们根本可以不认为它是三个 1 万维的向量, 我们想要描述它所需的信息只有一个 10000 项的数组以及"第二行是第一行的 2 倍, 第三行是第一行的 3 倍"这样一句简单的话. 我们根本不需要用 3 万个数字去描述一个矩阵, 而只需要 10002 个.* [4]

物理中, 自由度也是很重要的一个视角. 我们想象一下一个 3×3 矩阵, 分别对应着三维空间中的三个点. 当这个矩阵的秩为 3 的时候, 整个矩阵的元素几乎不受限制, 9 个元素可以自由地取值, 只需注意三个点和原点不共一个平面. [5] 一旦我们施加了一个约束, 比如说这三个点和原点组成平行四边形, 且原点和第三个点在对角线上, 那么它的秩就立刻削减为 2, 因为一旦确定了其中两个点, 那么第三个点的坐标就马上确定. 这种情况下, 物理视角上的自由度和线性代数视角上的秩是一样的.

关于秩还有很多有趣的理解, 读者可以自行体会. 你所学习的知识与学科愈多, 就越是能够感受到这一概念的神奇性和重要性.

5.4 秩 - 零化度定理

既然提到了几何视角, 就不得不提线性代数的核心基本定理.


对于一个 $m \times n$ 的矩阵 A (对应映射 $\mathbb{R}^n \rightarrow \mathbb{R}^m$, 分别记作空间 N 和 M):

$$\text{rank}(A) + \dim(\text{Nul } A) = n$$

即: **像空间的维数 + 零空间的维数 = 定义域的总维数.**

想象一个三维空间中垂直到 xy 平面上的投影, 原点对应着 z 轴, 它和 xy 平面刚好组成全三维空间^[6]. 换言之: 在空间 N 里, 有一个维数为 $n - \text{rank}(A)$ 的子空间, 它和 A 相"垂直". 这个空间里的点经过线性映射后被投射到原点, 这正好就是零空间的定义.

可以把线性映射想象成一台压路机: 在线性映射的过程中, 它会不可避免地压缩掉一些维度, 这些被压缩的维度就构成了核空间 $\text{Ker}(A)$, 这个被压缩的维度的数量就是零化度; 那些保留下来的维度则变成了一个扁扁的像空间 $\text{Im}(A)$. 这两个维数加起来当然等于全空间的维数 n .



因此我们也可以把这个定理写为:

$$\dim(\text{Im } A) + \dim(\text{Ker } A) = \dim(\text{The Space}) = n$$

其中根据定义 $\dim(\text{Im } A) = \text{rank } A$, $\dim(\text{Ker } A) = \dim(\text{Nul } A)$.

详细的证明涉及线性空间的基和同构, 用到基扩充定理. 在抽象代数中, 这实际上是同态基本定理. 物理学中, 这对应着空间的自由度等于规范冗余自由度加上实际自由度.

5.5 满秩与降秩

从这个角度, 我们很好理解下面的结论:

$$\text{满秩} = \text{行列式非 } 0$$

若一个矩阵满秩, 那么它把三维物体映为三维物体, 不会使得体积变为零, 而行列式恰好对应着体积变换的比例. 而若一个矩阵把三维空间变为二维平面, 也就相当于它把体积非零的三维物体变换为了体积为零的二维平面, 而这恰好对应了行列式等于零.

所以满秩刚好和我们在行列式这一章节所讲到的行列式非零的相关命题等价.

5.6 秩的运算法则与不等式

1. $\text{rank}(A) = \text{rank}(A^T) = \text{rank}(A^T A) = \text{rank}(A A^T)$.
2. 可逆矩阵不改变秩: 若 P, Q 可逆, 则 $\text{rank}(PAQ) = \text{rank}(A)$. 对应着我们上述所说的满秩矩阵不改变信息.^[7]
3. **加法不等式:** $\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$.

4. **乘法不等式:** $\text{rank}(AB) \leq \min(\text{rank}(A), \text{rank}(B))$.

我们可以把它理解为一道流水线. 物体先经过冲压机 A 压一遍, 再经过冲压机 B 压一遍, 那么它的维度肯定小于 A 和 B 中较小的那个.

5. **Sylvester 不等式:** 对于 $m \times n$ 的矩阵 A 和 $n \times p$ 的矩阵 B , 有 $\text{rank}(AB) \geq \text{rank}(A) + \text{rank}(B) - n$.

这需要用到秩 - 零化度定理. 对两边分别取零空间得到

$\dim(\text{Ker } AB) \leq \dim(\text{Ker } A) + \dim(\text{Ker } B)$. 我们考虑到 AB 的核空间是那些被 AB 映射到 0 的向量的集合, 而作为一个复合映射, 它要么被 B 映射到 0, 要么转化一道之后被 A 映射到 0, 两种情况的总维数刚好就是 $\dim(\text{Ker } A) + \dim(\text{Ker } B)$.

可以看到, 那些看起来复杂的不等式, 在我们掌握了秩相关的多个视角之后, 就变得轻而易举了.

6 特征值

有没有这样一些向量, 使得经过线性变换后的 $A\mathbf{x}$ 仍然和 $\mathbf{x}$ 处于同一方向, 即 $A\mathbf{x} = \lambda\mathbf{x}$ 呢?

易知, 零向量满足这个条件. 我们称这个解为平凡解. 而我们显然并不关注平凡解, 因此下面我们将研究那些非平凡的解及其特性.

6.1 特征值的定义

$A \in \mathbb{R}^{n \times n}$, $\mathbf{x}$ 为非零向量, 若存在数 λ 使得 $A\mathbf{x} = \lambda\mathbf{x}$ 有解, 则称 λ 为 A 的一个特征值, $\mathbf{x}$ 为对应于特征值 λ 的特征向量.

注意: 特征值不一定是实数!

- **矩阵视角:**

特征值是这样一个数: 矩阵减去它 (实则 λI) 后, 矩阵奇异 (不可逆).

- **几何视角:**

线性变换前后的线性空间都可以装进 $\mathbb{R}^n$ 里, 我们可以想象一堆 $\mathbb{R}^n$ 中的向量在线性变换下被拉伸, 移动等等. 而特征向量就代表了那些"方向不变"的向量. 特征值就代表了他们被拉伸的倍数.

6.2 特征值的性质

1. 原式等价于

$$(A - \lambda I)\mathbf{x} = 0$$

这也是常见的求特征值的一种方法.

2. 根据可逆矩阵定理我们可以知道, $A - \lambda I$ 一定不可逆. 也即:

$$\det(A - \lambda I) = 0$$

我们称这样一个行列式为**特征多项式**.

3. 一个特征值一定不只对应着一个特征向量. 因为如果 $\mathbf{x}$ 是特征向量, 那么, 所有形如 $k\mathbf{x}$ 的向量都一定是其特征向量. 可以证明, 每个特征值所对应向量方程 $(A - \lambda I)\mathbf{x} = 0$ 的解的集合一定对应着一个 $\mathbb{R}^n$ 或 $\mathbb{C}^n$ 的子空间, 我们称这个空间为**特征空间**. 特征空间可以是一条"直线", 一个"平面", 等等.

6.3 特征多项式

$$p_A(\lambda) = \det(A - \lambda I) = 0 = (\lambda - \lambda_1)^{n_1} (\lambda - \lambda_2)^{n_2} \dots (\lambda - \lambda_s)^{n_s}$$

其中 $\lambda_i \in \mathbb{C}$, $n_i \geq 1$, $\sum n_i = n$. 通过求解特征多项式, 可以得到每个特征值的精确值. 根据代数知识:

- 奇数维实矩阵必有实特征值.
- 实矩阵的特征值一定以共轭复数的形式成对出现

6.3.1 重数

由此我们引出两个极其重要的概念, 它们直接决定了矩阵能否被对角化:

1. 代数重数 (Algebraic Multiplicity, m_a):

特征值 λ_i 在特征多项式中作为根的重数, 即上面的 n_i .

2. 几何重数 (Geometric Multiplicity, m_g):

特征值 λ_i 对应的特征空间的维数, 即 $\dim \text{Ker}(A - \lambda_i I)$. 换句话说, 就是属于该特征值的极大线性无关特征向量的个数.

6.3.2 重数不等式

对于任意矩阵的任意特征值, 必定满足如下关系:

$$1 \leq m_g \leq m_a \leq n$$

几何重数永远不可能超过代数重数. 当两者相等时, 矩阵完美且可对角化; 当 $m_g < m_a$ 时, 则说明特征空间存在一定的"缺陷", 我们只能退而求其次寻找 Jordan 标准形. 这将在之后提到.

6.4 特征值的性质

根据上述推导, 我们可以得到矩阵的一些普遍性质. 矩阵经过简单的代数运算后, 其特征值也会相应变化:

1. **平移:** $A + cI$ 的特征值是 $\lambda + c$.
2. **数乘:** cA 的特征值是 $c\lambda$.
3. **逆矩阵:** A^{-1} 的特征值为 λ^{-1} .
4. **矩阵的幂:** A^k 的特征值为 λ^k .

5. **矩阵多项式**: 若 $f(x)$ 为一多项式, 则 $f(A)$ 的特征值为 $f(\lambda)$.
6. 上述五条性质均不改变特征向量.
7. **转置矩阵**: A^T 的特征值与 A 完全相同, 但特征向量不同.

下面是一些计算性质:

1. $\text{Tr}(A) = \sum \lambda_i$
2. $\det A = \prod \lambda_i$
3. 换言之, 只要有一个特征值为 0, 矩阵必定不可逆. 这个特征值所对应的特征空间也就是核空间.

6.5 线性无关定理

属于不同特征值的特征向量, 必定线性无关. 这也提供了一个推论: 如果一个 n 维方阵具有 n 个互不相同的特征值, 那么它必定拥有 n 个线性无关的特征向量, 从而一定可以对角化.

至于什么是对角化? 请看下一小节矩阵的相似.

7 矩阵的相似

7.1.1 相似的定义

两个 $n \times n$ 矩阵 A 和 B 相似, 指的是:

$$B = P^{-1}AP$$

其中 P 是一个可逆矩阵. 这等价于 $PB = AP$.

容易验证, 相似是一个等价关系, 每个类称为一个相似类.

7.1.2 唯一性?

P 不是唯一的. 若 A 与 Q 可交换, 我们有:

$$\begin{aligned} \because AQ &= QA \\ \therefore A &= Q^{-1}AQ \\ &= Q^{-1}(P^{-1}BP)Q \\ &= (PQ)^{-1}B(PQ) \end{aligned}$$

总之我们证否了唯一性.

7.1.3 相似的理解

如何从不同视角去理解呢？

基变换视角 (这个有点抽象, 可以不记忆):

- A 是线性变换 T 在原始基底 $\mathfrak{B}$ 下的表示;
- B 是同一个变换 T 在新基底 $\mathfrak{B}'$ 下的表示;
- P 是把 $\mathfrak{B}'$ -基坐标转换到 $\mathfrak{B}$ -基的变换矩阵.

线性映射视角:

- A 是线性变换 T 在自然基下的表示.
- C 的各个列向量构成一组基 $\mathfrak{C}$.
- 则: B 就是线性变换 T 在基 $\mathfrak{C}$ 下的表示.

试举一例:

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, C = \begin{bmatrix} 2 & -2 \\ 1 & 1 \end{bmatrix}, C^{-1}AC = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

其中 A 是把 x 轴放大两倍, y 轴放大两倍的仿射变换. 而在 C 下看来, 也是对角线方向伸缩两倍, 故其和 A 一样.

$$A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}, C = \begin{bmatrix} 2 & -2 \\ 1 & 1 \end{bmatrix}, C^{-1}AC = \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}$$

此时, A 为沿着 x 轴方向放大四倍, 对 C 而言是副对角线方向增大四倍.

果然, 对于变换后的矩阵而言, 其效果相当于主对角线放大两倍, 副对角线放大四倍.

7.1.4 相似的性质

谱性质:

1. 相似的矩阵具有相同的**特征多项式**, 这是因为 $P^{-1}IP = I$.
2. 从而具有相同的**特征值**.
3. 也即其**代数重数**相同.
4. 可以证明其**几何重数**也相同.

5. 对于**特征向量**而言, 如果 v 是 A 的特征向量, 那么: $w = P^{-1}v$ 是 B 的特征向量.

$$Bw = P^{-1}AP(P^{-1}v) = P^{-1}Av = P^{-1}(\lambda v) = \lambda(P^{-1}v) = \lambda w$$

代数量的性质:

6. 从而, 相似的矩阵一定具有相同的迹.
 7. 具有相同的行列式.
 8. 具有相同的秩.
 9. 相同的 Jordan 标准形. (这个神秘概念在后面才会出现)
- 本质上, 相似矩阵就是同一个线性变换在不同基视角下的体现.

7.2 对角化

既然, 相似的矩阵都在同一个相似类, 那我们可以推断, 相似类的矩阵中一定有某种矩阵的形式最简单. 很容易想到, 我们可以把对角矩阵当做这个最简矩阵. 这就叫做矩阵的对角化.

7.2.1 对角化的概念

若一个矩阵可以写成诸如 $A = P^{-1}DP$ 的形式, 其中 D 为对角阵, 那么我们就称矩阵是可以对角化的. 其中, $D = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$.

7.2.2 对角化的理解

矩阵视角:

易知对角矩阵是最容易进行次幂运算的.

因此, 将矩阵对角化有利于我们进行次幂运算, 这是因为可逆矩阵在次幂运算中相互抵消, 只留下了对角化矩阵的 n 次方.

基变换视角:

对角化就是: 在线性变换 T 下, 存在一些特殊的基底, 使得在这个基底下, T 的效果是:

1. 把每个方向 v_i 直接拉伸为 $\lambda_i v_i$;
2. 不改变其他方向.

几何视角:

几何上, 对角化就是找到所有在线性变换中不被旋转的方向.

7.2.3 对角化的性质

1. 对角化中, 对角矩阵对角线上的元素 λ_i 就是矩阵的特征值. 而其所对应的矩阵 P 的列向量, 就是所对应的特征向量.
2. 我们可以知道, 矩阵能够对角化的充要条件是: **矩阵有 n 个线性无关的特征向量**. 而由于特征值代数重数为 λ_i , 几何重数一定小于代数重数, 属于矩阵的不同特征值的向量也一定是线性无关的. 所以这句话也可改写为, **每个特征值的代数重数和几何重数相同**.
3. 推论: 所有特征值各不相同的矩阵一定能够对角化. 这正是我们引入线性无关定理的作用.

8 Jordan 标准形

本部分通常不作为考点

本部分通常不作为考点

本部分通常不作为考点

科大的教材中对这一部分的描述甚少, 故我将其单独开一小节.

对角化是将矩阵相似于对角阵, 不过那些无法相似于对角阵的矩阵当然也能够对角化. 那我们该用什么"标准形"去描述它们呢?

当矩阵的特征值有重根, 且其对应的几何重数小于代数重数, 矩阵不可对角化. 换言之, 其特征空间不够大, 无法塞满可逆矩阵.

美好的愿景, 终究无法实现. 最简化为对角矩阵的希冀已成泡影. 但是我们仍然期盼, 能够找到一个尽可能简单的矩阵类型. 这就是 **Jordan 标准型**.

8.1.1 上三角矩阵分解

(注意这不是 *Schur 分解定理*) 任意一个 $n \times n$ 的复矩阵 A , 都存在一个复矩阵 Q , 使得:

$$A = Q^{-1}TQ$$

其中, T 是一个上三角矩阵, 其对角线上的元素是其特征值.

8.2 Jordan 块的定义

一个大小为 $n \times n$, 对应的特征值为 λ 的若当块如下:

$$J_n(\lambda) = \begin{bmatrix} \lambda & 1 & 0 & \cdots & 0 \\ 0 & \lambda & 1 & \cdots & 0 \\ 0 & 0 & \lambda & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \lambda \end{bmatrix}$$

可以称为特征值 λ 的 n 阶 Jordan 块.

可知, 当阶数为 i 时, Jordan 块退化为一个 1×1 矩阵也就是一个数. 这就是我们上文所提到的理想化矩阵的情况.

8.3 Jordan 块的性质

Jordan 块并非我们随意定义的, 它实际上蕴含着许多优雅的性质:

8.3.1 特征向量唯一

Jordan 块只有一个特征向量, 其几何重数为 1, 那就是 $\mathbf{v}_1 = (1, 0, \dots, 0)^T$. 它对应的特征值就是 λ .

8.3.2 特征向量链

考虑 $\mathbf{v}_2 = (0, 1, \dots, 0)^T$, 我们可以得到:

$$(J_n(\lambda) - \lambda I)\mathbf{v}_2 = \mathbf{v}_1$$

这也描绘了特征空间的重数不足时, Jordan 块如何在"某种程度上"去补足特征空间.

8.3.3 Jordan 块的幂次:

我们考虑 $J_n(\lambda) - kI$:

1. $k \neq \lambda$:

很明显, 其为满秩阵, 不管幂次是多少次, 都满秩.

2. $k = \lambda$:

考虑一个偏离主对角线 p 格且这一行上全部是一的矩阵. 它对另一个类似矩阵的作用就是让其向上平移 p 格.

对于 $(J_n(\lambda) - \lambda I)$ 而言, $p = 1$. 原本其秩为 $n - 1$, 每自乘一次秩减一, 直到 $\text{rank}(J_n(\lambda) - \lambda I)^n = 0$.

对于对角矩阵而言, 其幂次就是各对角块分别取幂次, 这提示了我们 Jordan 标准型的构造.

8.4 Jordan 标准型

8.4.1 定义

Jordan 标准型是一个块对角矩阵 J , 其对角线上的每一个块, 都是一个关于 A 的某个特征值 λ_i 的 Jordan 块 $J_{n_{ij}}(\lambda_i)$. 并且, 任何一个复方阵 A 都相似于一个 Jordan 标准形.

8.4.2 性质

其中:

- 每个特征值的代数重数 m_a , 对应了其 Jordan 块的阶数之和.
- 每个特征值的几何重数 m_g , 对应了其 Jordan 块的个数.

但是这仍然无法唯一确定一个 Jordan 块, 所以我们还需要高阶技巧 (特征向量链或高阶秩分析).


8.4.3 秩序列

首先, 根据相似的原理我们可知, $\text{rank}(J - \lambda I)^k = \text{rank}(A - \lambda I)^k$

我们可以反复计算 $\text{rank}(J - \lambda I)^k$ 的值, 假设一个特征值的代数重数为 4, 几何重数为 2, 其秩序列结构为如下这样:

$$\begin{cases} \dim \text{Nul } N^1 = 2 \\ \dim \text{Nul } N^2 = 3 \\ \dim \text{Nul } N^3 = 4 \end{cases}$$

那么我们顺着构造:



其中, 横着的格子数 (列数) 代表了几何重数, 也就是 Jordan 块的个数. 竖直方向上黑色格子的个数代表了 Jordan 块的阶数.

由于 Jordan 块每自乘一次秩减一. 根据秩定理, 零空间的维数加一. 我们可以从顺推, 何时零空间的秩加一, 就说明这个时候, 有一个 Jordan 块.

当然你也可以通过对这样一个序列求两次公差来判断何时出现了几个 Jordan 块, 但我们显然不需要用这种复杂的技巧.

8.4.4 根向量

若满足 $(A - \lambda I)^k v = 0$ 而 $(A - \lambda I)^{k-1} v \neq 0$, 就称 v 是属于特征值 λ 的 k 次根向量.

9 内积空间

9.1 内积的四公理

对于实数^[8]来说:

1. 正定性: $\langle a, a \rangle \in \mathbb{R}^{\geq 0}$.
2. 共轭对称性 (对于实数来说就是对称性).
3. 第一变元的齐次性.
4. 第一变元的可加性.

因此我们在这个笔记中只讨论实数.^[9] 上述内容只是指出, 内积的"对称性""齐次性"无法想当然直接推广到复数域.

欧式空间中的内积满足: **正定性, 线性性, 对称性**.

9.2 内积的定义

设列向量 $a, b \in \mathbb{R}^n$, 度量矩阵 $G \in \mathbb{R}^{n \times n}$, 则定义其内积为:

$$\langle a, b \rangle = a^T G b$$

其中 G 满足 $G^T = G$, $x^T G x > 0$, 称这种方阵为实对称正定方阵, 具体概念在二次型中讲到.

9.3 内积相关量的定义

我们可以类比立体几何里的内容定义向量的长度和夹角.

1. 长度 (模), 或称其为一种范数:

$$|\boldsymbol{x}| = \sqrt{\langle \boldsymbol{x}, \boldsymbol{x} \rangle}$$

2. 夹角:

$$\theta = \arccos \frac{\langle \boldsymbol{a}, \boldsymbol{b} \rangle}{|\boldsymbol{a}| |\boldsymbol{b}|}$$

3. 单位化:

$$\hat{\boldsymbol{a}} = \frac{\boldsymbol{a}}{|\boldsymbol{a}|}$$

9.4 Cauchy - Schwarz 不等式

对于任意两个向量和任意内积, 都有:

$$|\langle \boldsymbol{u}, \boldsymbol{v} \rangle| \leq |\boldsymbol{u}| \cdot |\boldsymbol{v}|$$

1. 欧式空间:

$$\left(\sum_{i=1}^n u_i v_i \right)^2 \leq \left(\sum_{i=1}^n u_i^2 \right) \left(\sum_{i=1}^n v_i^2 \right)$$

2. 复线性空间:

$$\left(\sum_{i=1}^n u_i \overline{v_i} \right)^2 \leq \left(\sum_{i=1}^n |u_i|^2 \right) \left(\sum_{i=1}^n |v_i|^2 \right)$$

3. Hilbert space:

$$\left| \int_a^b f(x) \overline{g(x)} dx \right|^2 \leq \left(\int_a^b |f(x)|^2 dx \right) \left(\int_a^b |g(x)|^2 dx \right)$$

4. 带权函数空间:

$$\left| \int_a^b f(x) \overline{g(x)} w(x) dx \right|^2 \leq \left(\int_a^b |f(x)|^2 w(x) dx \right) \left(\int_a^b |g(x)|^2 w(x) dx \right)$$

9.5 正交

类比二维空间和三维空间中垂直的概念, 我们能否定义一个高维线性空间甚至是抽象线性空间中的垂直呢?

9.5.1 正交定义

设 $a, b \in \mathbb{R}^n$, 则 $a \perp b$ 当且仅当:

$$\langle a, b \rangle = 0$$

也即 (勾股定理):

$$|a + b|^2 = |a|^2 + |b|^2$$

9.5.2 正交补

若向量 z 和 $\mathbb{R}^n$ 的子空间 W 内任意一个向量都正交, 我们称其正交于 W ; 全体这种向量的集合称为 W 的**正交补**, 记作 $W^\perp$.

→ 我们可以得到:

$$(\text{Row } A)^\perp = \text{Nul } A \quad \text{and} \quad (\text{Col } A)^\perp = \text{Nul } A^T$$

9.5.3 向量下的投影

考虑将一个向量分解成两个向量 $y = \hat{y} + z$, 其中 $\hat{y}$ 是 u 的倍数, z 与 u 正交. (注意这里的 $\hat{y}$ 并不是单位向量的意思). 我们有:

$$\hat{y} = \text{proj}_\perp y = \frac{y \cdot u}{u \cdot u} u$$

称其为 y 在 u 上的正交投影.

- 向量角度:
- 几何角度:
过 y 作垂线, 或称作投影向量.

9.5.4 子空间下的投影

若 W 是 $\mathbb{R}^n$ 的一个子空间, $\{u_1, u_2, \dots, u_p\}$ 是 W 的任意正交基, 那么 $\mathbb{R}^n$ 中的向量可以唯一分解为 $y = \hat{y} + z$, 其中 $y \in W, z \in W^\perp$. 且有:

$$\begin{aligned}\hat{y} &= \text{proj}_W y = \frac{y \cdot u_1}{u_1 \cdot u_1} u_1 + \frac{y \cdot u_2}{u_2 \cdot u_2} u_2 \cdots + \frac{y \cdot u_p}{u_p \cdot u_p} u_p \\ &= \text{proj}_{u_1} y + \text{proj}_{u_2} y \cdots + \text{proj}_{u_p} y \\ z &= y - \hat{y}\end{aligned}$$

此即为类比于"线面垂直"的正交投影.

实际上这个所谓"正交基"也可以是一些相互正交且直和为 W 的子空间, 公式带进去仍然是一样的:

$$\hat{y} = \text{proj}_W y = \text{proj}_{W_1} y + \text{proj}_{W_2} y \cdots + \text{proj}_{W_q} y$$

9.6 标准正交基

在二维和三维空间中, 我们使用的坐标系一般都是两两垂直的单位向量坐标系. 而在其他线性空间中, 又怎么定义它呢?

9.6.1 Kronecker Delta^[10]

Kronecker 符号的定义是:

$$\delta_{ij} = \begin{cases} 1 & \text{if } i = j \\ 0 & \text{if } i \neq j \end{cases}$$

9.6.2 标准正交基的定义

在 $\mathbb{R}^n$ 或 $\mathbb{C}^n$ 中, 向量组构成一组标准正交基 $\{e_1, e_2, \dots, e_n\}$ 当且仅当:

$$\langle e_i, e_j \rangle = \delta_{ij}$$

且

$$|e_i| = 1$$

9.6.3 标准正交基的优越性

标准正交基確有優越之處！

1. 坐标计算简单, 系数 $c_i = \langle v, e_i \rangle$, 即为 v 在 e_i 方向的投影长度. 无需像其他基一样计算复杂的线性方程组.
2. 由此, 在坐标之下的各种内积定义量也简单. 比如, 模长和角度 (余弦相似度) 等.
3. 便于求对应矩阵的逆.

9.7 正交矩阵

9.7.1 正交矩阵定义

若

$$A = A^T$$

则称 A 是一个正交阵.

这样的矩阵有单位正交列, 且:

1. 单位阵是正交方阵.
2. 若 A, B 正交, 则 AB 也正交.
3. 若 A 正交, $A^T = A^{-1}$, 也正交.
4. $\det A = \pm 1$.
5. 其特征值的复数模长为 1.

9.7.2 正交阵乘向量的性质

1. 保模长:

$$|Ux| = |x|$$

2. 保内积:

$$\langle Ux, Uy \rangle = \langle x, y \rangle$$

9.8 Gram-Schmidt 正交化

既然正交基有如此好的性质, 那我们该如何从一个子空间的一般基里得到一个正交基呢?

Gram-Schmidt 正交化正是一种在内积空间中, 将一组线性无关的向量转化为一组正交 (正交归一) 向量的过程.

先给定初始条件: 有一组线性无关的向量组

$$\{v_1, v_2, \dots, v_n\} \subset \mathbb{R}^m$$

我们希望从中构造出一组正交向量组, 并且保持其张成子空间不变.

$$\{u_1, u_2, \dots, u_n\}$$

9.8.1 步骤:

1. 初始化第一个向量:

$$u_1 = v_1$$

2. 对于第 k 个向量 ($k \geq 2$), 从 v_k 中减去它在之前所有 u_i 上的投影:

$$\begin{aligned} \mathbf{u}_k &= \mathbf{v}_k - \sum_{j=1}^{k-1} \mathrm{proj}_{\mathbf{u}_j} \mathbf{v}_k \\ &= \mathbf{v}_k - \sum_{j=1}^{k-1} \frac{\mathbf{v}_k \cdot \mathbf{u}_j}{\mathbf{u}_j \cdot \mathbf{u}_j} \mathbf{u}_j \end{aligned}$$

到此步骤已经完成正交化.

3. 若要构造单位正交阵, 若需要, 可以将每个 u_k 单位化:

$$e_k = \frac{u_k}{\|u_k\|}$$

9.8.2 理解

每次处理一个新的向量时, 我们从它身上"剔除"掉它在已构造出的正交子空间中的部分. 因而, 最终保留下来的部分就是和已有向量正交的那一部分. 每次构造出的新向量都和"子子空间"正交, 其自己又和子子空间构成新的子子空间...

9.9 最小二乘解

我们常会遇到以下一个问题: 我们希望找出使得

$$|\mathbf{b} - A\mathbf{x}|$$

尽量小的 $\mathbf{x}$. 我们把这个解叫做 $\hat{\mathbf{x}}$, 即方程的最小二乘解.

9.9.1 引理

$\mathbf{v}$ 与 A 的列空间正交的充要条件是:

$$A^T \mathbf{x} = \mathbf{0}$$

9.9.2 推导

取

$$\hat{\mathbf{b}} = \text{proj}_{\text{Col } A} \mathbf{b}$$

可知, $\hat{\mathbf{b}} \in \text{Col } A$, 下列方程一定有解:

$$A\hat{\mathbf{x}} = \hat{\mathbf{b}}$$

故由于 $\mathbf{b} - \hat{\mathbf{b}}$ 和 $\text{Col } A$ 正交, 可以知道:

$$A^T(\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{0}$$

也即:

$$A^T A \hat{\mathbf{x}} = A^T \mathbf{b}$$

这称作 $A\mathbf{x} = \mathbf{b}$ 的法方程.

10 实对称矩阵

我们知道, 相似矩阵实际上是相同线性变换在不同视角下的变化. 既然已经学了正交矩阵, 我们不禁要问, 正交矩阵所对应的线性变换是什么样的?

10.1 正交变换

正交矩阵对应的线性变换叫正交变换, 我们已经在上一章中学到了其对向量的作用. 但我们并未从线性变换的视角解读. 实际上, 我们留在了这里解读.

- **矩阵视角:**
满足 $Q^T Q = I$.
- **基变换视角:**
对一组两两垂直的单位基进行加权.
- **几何视角:**
正交变换对应的是欧几里得空间中的旋转和反射.
正交变换保持了距离, 角度, 面积, 体积 (行列式) 等.
其他性质, 详见上一章.

10.2 对称矩阵谱定理

矩阵的特征值有时称为矩阵的谱.

10.2.1 特征值均为实数

设 A 是一个 $n \times n$ 的实对称矩阵, $\boldsymbol{v}$ 是其一个特征向量, 对应特征值 λ , 即:

$$A\boldsymbol{v} = \lambda\boldsymbol{v}$$

和共轭转置取内积, 得:

$$\boldsymbol{v}^H A \boldsymbol{v} = \lambda \boldsymbol{v}^H \boldsymbol{v}$$

因为 A 是实对称矩阵, 满足 $A = A^T = A^H$, 所以有:

$$\boldsymbol{v}^H A \boldsymbol{v} = (A\boldsymbol{v})^H \boldsymbol{v} = (\lambda\boldsymbol{v})^H \boldsymbol{v} = \bar{\lambda} \boldsymbol{v}^H \boldsymbol{v}$$

因此:

$$\lambda \boldsymbol{v}^H \boldsymbol{v} = \bar{\lambda} \boldsymbol{v}^H \boldsymbol{v}$$

若 $\mathbf{v} \neq 0$, 则 $\mathbf{v}^H \mathbf{v} > 0$, 可得:

$$\lambda = \bar{\lambda}$$

即: λ 为实数.

10.2.2 几何重数等于代数重数

10.2.3 不同特征值对应的向量两两正交

设 A 是实对称矩阵, $\mathbf{v}_1, \mathbf{v}_2$ 是 A 的两个特征向量, 对应特征值 $\lambda_1 \neq \lambda_2$, 则:

$$A\mathbf{v}_1 = \lambda_1\mathbf{v}_1, \quad A\mathbf{v}_2 = \lambda_2\mathbf{v}_2$$

考虑对 $\mathbf{v}_2$ 取内积:

$$\mathbf{v}_2^T A\mathbf{v}_1 = \mathbf{v}_2^T \lambda_1 \mathbf{v}_1 = \lambda_1 \mathbf{v}_2^T \mathbf{v}_1$$

另一方面, 因 A 对称:

$$\mathbf{v}_2^T A\mathbf{v}_1 = (A\mathbf{v}_2)^T \mathbf{v}_1 = (\lambda_2 \mathbf{v}_2)^T \mathbf{v}_1 = \lambda_2 \mathbf{v}_2^T \mathbf{v}_1$$

综上两式:

$$\lambda_1 \mathbf{v}_2^T \mathbf{v}_1 = \lambda_2 \mathbf{v}_2^T \mathbf{v}_1$$

因 $\lambda_1 \neq \lambda_2$, 可得:

$$\mathbf{v}_2^T \mathbf{v}_1 = 0$$

即 $\mathbf{v}_1$ 与 $\mathbf{v}_2$ 正交.

由于任意性, 任意两个特征值不同的向量都正交.

10.3 正交对角化

由上可知: 任意阶实矩阵都可正交对角化.

10.3.1 定义

设 A 是一个 $n \times n$ 的实对称矩阵, 则 A 可以**正交对角化**, 即存在一个正交矩阵 Q 和一个实对角矩阵 Λ , 使得:

$$A = Q\Lambda Q^T$$

其中:

- Q 的列是 A 的一组单位正交特征向量;
- Λ 是对角矩阵, 其对角元是 A 的特征值们.

10.3.2 理解

设 $A = Q\Lambda Q^T$, 其中 A 是实对称矩阵, Q 是正交矩阵, Λ 是实对角矩阵.

- Q^T : 将原坐标系旋转到特征向量构成的新坐标系.
- Λ : 在新坐标系中, 按特征值进行拉伸或压缩.
- Q : 将变换后的结果再旋转回原坐标系.

正交对角化相当于在适当的正交坐标系中, 对空间进行轴向缩放, 再转回原来的坐标系.

10.3.3 谱分解

设 A 是一个 $n \times n$ 的实对称矩阵, 具有如下特征分解:

- 特征值: $\lambda_1, \lambda_2, \dots, \lambda_n$.
- 单位正交特征向量: $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$.

也即, A 可以正交分解为:

$$A = PDP^T = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \begin{bmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \vdots \\ \mathbf{u}_n \end{bmatrix}$$

则 A 可以表示为:

$$A = \lambda_1 \mathbf{v}_1 \mathbf{v}_1^T + \lambda_2 \mathbf{v}_2 \mathbf{v}_2^T + \dots + \lambda_n \mathbf{v}_n \mathbf{v}_n^T$$

这就是矩阵的谱分解.

10.4 酉空间

这是正交矩阵在复数空间的推广. 为了了解它, 我们必须先定义复数空间的内积.

10.4.1 复数内积

给定两个复向量, 其内积定义为:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^n \overline{x_i} y_i = \mathbf{x}^H \mathbf{y}$$

复内积满足以下几个性质:

1. **共轭对称性:** $\langle \mathbf{x}, \mathbf{y} \rangle = \overline{\langle \mathbf{y}, \mathbf{x} \rangle}$
 2. **共轭线性性:** 不举例.
 3. **正定性:** $\langle \mathbf{x}, \mathbf{x} \rangle \geq 0$, 等号成立当且仅当 $\mathbf{x} = \mathbf{0}$.
- 总之, 我们可以就此定义很多内积量

10.4.2 酉矩阵

一个复矩阵 $U \in \mathbb{C}^{n \times n}$ 是**酉矩阵**, 当且仅当:

$$U^H U = U U^H = I$$

10.4.3 酉矩阵的性质

- $\overline{A}, A^T, A^{-1}$ 都是酉方阵.
- 保模长: 即 $|U\mathbf{x}| = |\mathbf{x}|$.
- 保内积: $\langle U\mathbf{x}, U\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle$.
- 特征值模长为 1.
- 列 (或行) 向量两两正交且模长为 1.

10.4.4 酉对角化

Hermitian 矩阵是形如 $A^H = A$ 的矩阵.

存在酉矩阵 U , 使得

$$U^H A U = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

其中 λ_i 为实数.

即:

- Hermitian 矩阵的特征值均为实数.
- 可酉对角化.

11 实二次型

11.1 定义

设 $A \in \mathbb{R}^{n \times n}$ 是一个实对称矩阵, $\mathbf{x} \in \mathbb{R}^n$ 是列向量, 则对应的实二次型定义为:

$$Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$$

其中, 若 $\mathbf{x} = (x_1, x_2, \dots, x_n)$, 则:

$$Q(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$$

因为 A 是对称矩阵, 交叉项 (如 $x_i x_j$) 可以合并成一项, 系数为 $2a_{ij}$. 矩阵的秩称为二次型的秩.

直观理解二次型的方式就是, 如下想象:

	x_1	x_2	x_3	$\cdots$	x_n
x_1	a_{11}	a_{12}	a_{13}	$\cdots$	a_{1n}
x_2	a_{21}	a_{22}	a_{23}	$\cdots$	a_{2n}
x_3	a_{31}	a_{32}	a_{33}	$\cdots$	a_{3n}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
x_n	a_{n1}	a_{n2}	a_{n3}	$\cdots$	a_{nn}

11.2 相合变换

11.2.1 定义

设 $A, B \in \mathbb{R}^{n \times n}$ 是两个实对称矩阵, 如果存在一个可逆矩阵 P , 使得:

$$B = P^T A P$$

则称 A 与 B 相合.

注意到, 相合关系具有自反性, 对称性, 传递性, 因此其作为一种等价关系.

11.3 二次型化简

11.3.1 标准型

设原始二次型为

$$Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$$

我们作变量代换

$$\mathbf{x} = P\mathbf{y}$$

将 Q 化为

$$\begin{aligned} Q(\mathbf{x}) &= \mathbf{x}^T (P^T D P) \mathbf{x} \\ &= (P\mathbf{x})^T D (P\mathbf{x}) \\ &= \mathbf{y}^T D \mathbf{y} \\ &= \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2 \end{aligned}$$

其中 D 是对角矩阵.

11.3.2 配平方法

通过配方法变换变量 $(x_1, \dots, x_n) \rightarrow (y_1, \dots, y_n)$, 使得:

$$Q(x_1, \dots, x_n) = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2$$

步骤为:

1. 按照变量顺序逐个配平方;
2. 每次用线性代换消去该变量与后面变量的交叉项, 使得整个后面的式子不存在这一项;
3. 反复操作, 直到只剩平方项.

实际上配平方就是在求相合矩阵.

11.3.3 初等变换法

1. 构造增广矩阵:

将矩阵 A 放在左边, 同时在右边附上单位阵 I , 形成增广矩阵:

$$[A | I]$$

我们会在 A 上进行初等变换, 同时对 I 做同样的操作以追踪变量替换过程.

2. 进行初等行列变换:

使用对称的初等变换将 A 化为对角矩阵. 即: 同时对第 i 行和第 i 列做变换.

对称操作的目的是, 确保每一步操作都保持矩阵对称性. 结果为

$$[P^T AP \mid P]$$

变换后原本为单位矩阵的部分即为矩阵 P , 满足:

$$P^T AP = D$$

11.4 主轴定理

11.4.1 对称阵的对角化

显然根据正交相似, 我们有:

$$P^T AP = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

11.4.2 主轴定理

由上可知:

$$Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x} = \mathbf{y}^T D \mathbf{y} = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \dots + \lambda_n y_n^2$$

变换后变量 $y_1, \dots, y_n$ 所对应的新坐标系的轴, 称为主轴方向.

主轴和这些向量组是不唯一的, 但是既然相合是一个等价类, 就理应有类似的标准型. 我们可以证明, 实际上:

11.5 相合标准型

对任意实对称矩阵 A , 存在一个可逆矩阵 P , 使得:

$$P^T AP = \text{diag}(1, \dots, 1, -1, \dots, -1, 0, \dots, 0)$$

即:

$$P^T A P = \begin{bmatrix} I_p & 0 & 0 \\ 0 & -I_q & 0 \\ 0 & 0 & 0_r \end{bmatrix}$$

其中:

- I_p 是 $p \times p$ 的单位矩阵.
- $-I_q$ 是 $q \times q$ 的负单位矩阵.
- 0_r 是 $r \times r$ 的零矩阵.
- $p + q + r = n$.

由此我们可以导出下面的惯性定理.

11.5.1 惯性定理

我们找到了一个相合不变量: 即不论进行如何的相合变换; 正, 负, 零的对角元个数 (即 p, q, r) 都是不变量.

实际上, 这三个数可以根据主轴定理里的特征值的正负性看出.

这三个数分别称为:

- **正惯性指数** p
- **负惯性指数** q
- **零惯性指数** r

由惯性指数, 我们可以给出很多二次型的分类, 比如:

11.5.2 分类

1. 二维:

椭圆 双曲 抛物线.

2. 三维:

椭球 双曲 抛物 二次锥 二次柱.

11.6 正定二次型

11.6.1 二次型的分类

一个二次型是:

- 正定的, 如果对所有 $x \neq 0$ 都有 $Q(x) > 0$;
- 半正定的, 如果对所有 $x \neq 0$ 都有 $Q(x) \geq 0$;

- 负定的, 如果对所有 $x \neq 0$ 都有 $Q(x) < 0$;
- 半负定的, 如果对所有 $x \neq 0$ 都有 $Q(x) \leq 0$;
- 不定的, 如果正负都有.

11.6.2 正定性质

我们先只讨论正定. 易知, 其充要条件为: 正惯性指数等于 n .
由此可知:

- 矩阵满秩;
- 矩阵相合于单位阵;
- 矩阵的所有特征值都是正数;
- A 所有**顺序主子式**为正.

那么什么是顺序主子式呢?

11.6.3 Sylvester 判据

即: A 正定的充要条件为, A 所有顺序主子式为正

A 的 k 阶顺序主子式是指从左上角开始的 $k \times k$ 子矩阵的行列式:

$$D_k = \det \begin{bmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{bmatrix}, \quad k = 1, 2, \dots, n$$

正定当且仅当所有顺序主子式均为正:

$$\det(A_k) > 0, \quad k = 1, 2, \dots, n$$

负定矩阵则稍微复杂. 负定当且仅当顺序主子式符号交替变化, 且奇数阶主子式为负, 偶数阶主子式为正, 即:

$$(-1)^k \det(A_k) > 0, \quad k = 1, 2, \dots, n$$

这个判据在判断二次型的正定性的时候非常好用!

11.6.4 半正定性质

类比可知:

- 负惯性指数为 0.

- 特征值大于等于 0.
- 行列式大于等于 0.

11.7 条件约束极值

设目标函数是一个二次型:

$$Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}, \quad A = A^T \in \mathbb{R}^{n \times n}$$

要求在约束条件:

$$\mathbf{x}^T \mathbf{x} = 1$$

下, 使 $Q(\mathbf{x})$ 取极小值或极大值.

可转化为, 在单位球面上使 $Q(\mathbf{x})$ 取极值, 进而可转化为特征值问题.

结论如下:

- 极大值: 最大特征值 λ_1 ;
 - 极小值: 最小特征值 λ_n ;
- 且取值点为对应特征向量.

若进一步强化约束条件, 使得 $\mathbf{x}^T \mathbf{u}_i = 0$, 那么最大值可以取到第二大特征值 λ_2 .

以此类推, 可求任意约束条件.

11.8 奇异值分解 (SVD)

本章并不是线性代数 B 的考点, 了解即可.

奇异值分解是矩阵分解理论中最为普遍的形式, 它将正交对角化的思想从实对称方阵推广到了任意维度的实矩阵.

11.8.1 SVD 的定义

设 $A \in \mathbb{R}^{m \times n}$ 且 $\text{rank}(A) = r$. 则存在正交矩阵 $U \in \mathbb{R}^{m \times m}$ 和 $V \in \mathbb{R}^{n \times n}$, 以及一个准对角矩阵 $\Sigma \in \mathbb{R}^{m \times n}$, 使得:

$$A = U \Sigma V^T$$

其中:

- $U = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m]$, 其列向量称为**左奇异向量**.
- $V = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n]$, 其列向量称为**右奇异向量**.
- Σ 的非零元素全在主对角线上, 记为 $\sigma_1, \sigma_2, \dots, \sigma_r$, 称为**奇异值**. 通常规定它们按降序排列: $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$.

11.8.2 几何变换视角

任意线性映射 $\mathcal{A}: \mathbb{R}^n \rightarrow \mathbb{R}^m, \mathbf{x} \mapsto A\mathbf{x}$, 通过 SVD 可以分解为三个基本变换的复合:

1. V^T : 在 $\mathbb{R}^n$ 内的正交变换, 把主轴方向旋转到右奇异向量对应的方向.
2. Σ : 从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的映射, 沿坐标轴进行缩放, 奇异值即为缩放系数.
3. U : 在 $\mathbb{R}^m$ 内的正交变换, 把主轴方向旋转到左奇异向量对应的方向.

注意上面所说的所有旋转其实是旋转或反射.

这也表明, 在 $\mathbb{R}^n$ 中的单位球面, 经过任意线性映射后, 在 $\mathbb{R}^m$ 中一定映射为一个超椭球面, 奇异值正是该超椭球半轴的长度. 奇异值也就代表着这个线性变换在哪些方向"用力"比较大, 哪些方向"用力"比较小.

11.8.3 Eckart - Young 截断定理

将 SVD 展写为外积的叠加形式, 这一步被称为外积展开:

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

Eckart - Young - Mirsky 定理指出: 若要求在秩不超过 k ($k < r$) 的矩阵集合中, 寻找一个与原矩阵 A 在 Frobenius 范数下距离最近的矩阵 A_k , 其最优解恰好由 SVD 的前 k 项截断给出:

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

差的范数可以被类比为"残差", 换言之, 前 k 项截断可以在压缩掉一部分冗余信息的情况下, 尽可能的贴合原矩阵. 这经常被用在图片压缩中. 对于一张图片而言, 其包含非常多的冗余信息. 我们只需要取前 k 项奇异值, 就可以在极大压缩体积的条件下保留尽可能多的信息.

11.8.4 Moore - Penrose 伪逆

对于非方阵或不可逆矩阵 A , 利用 SVD 可以定义其广义逆矩阵 A^+ :

$$A^+ = V\Sigma^+U^T$$

其中 $\Sigma^+ \in \mathbb{R}^{n \times m}$ 是将 Σ 的非零奇异值取倒数, 并转置矩阵形状得到的矩阵. 伪逆是满足 4 个 Penrose 方程的唯一解.

伪逆常被用在求最小二乘解的过程中. 同时也可以被用来解决冗余或病态系统.

11.9 一些之后的东西

在目前我们很少接触到的 QR 分解, LU 分解, SVD 分解, 乃至 Schur 分解等等, 是数值线性代数的核心之一. 如果说我们所涉及到的线性代数所追求的是准确与真理, 那么数值线性代数所讲究的就是妥协. 面对病态矩阵乃至极大稀疏矩阵时, 仍然保持完全准确的思维会极大的增加计算的难度以及存储的容量需求.

现代计算机计算能力的爆发, 很大程度上也来源于其学会了疯狂地做大量的矩阵运算的能力. 图形渲染, 图像处理, 大数据搜索, 乃至机器学习, 都会运用到大量这些我们在正常课程中一带而过的知识点. 略过它, 也只是因为我们的课程范围内不需要这些东西, 而并不代表它们不重要或是不美丽.

(完)

2026.7

1. 目前我们还只能做一些简单的处理, 学到特征值时, 迹的威力才会真正体现. 当你学习了张量分析并且知道了各种规范之后, 这个东西就不再看起来那么友善了. ↩
2. 这是在 LaTeX 里输入行列式两边那个 $||$ 的方法 ↩
3. 这一章涉及到秩的概念, 大家学完了秩再来看这一小节. ↩ ↩
4. 这种朴素的理解完全不是真正的信息论学科. 在这种秩为一的特殊情况下, 一个矩阵可以被拆分为向量与向量转置的外积, 或者用张量的视角来说, 是两个张量的张量积. ↩

5. 回想一下我们在高中所学过的三点共线定理: $\vec{OA} = \lambda\vec{OB} + (1 - \lambda)\vec{OC}$. 移项就会发现, 这其实等价于 OA 、 OB 、 OC 三个向量通过特定系数的组合可以等于 0 . 也就是说其线性相关. 线性相关性和共平面 / 共线的特性是一致的. $\hookleftarrow$
6. 严谨地说: 直和为 $\hookleftarrow$
7. 在后续的知识点中, 我们会遇到相似和相合变换, 可以知道它们是不改变秩的. $\hookleftarrow$
8. 这个定义比较暧昧, 但是我们先只引入向量和度量矩阵都是实数的内积. $\hookleftarrow$
9. 在量子力学的 Dirac 符号里也通常约定第二变元即右矢为线性, 第一变元为共轭线性. $\hookleftarrow$
10. 有点像くろねこ. $\hookleftarrow$